Essence of Optimization & Gradient Descent for ChE

ศุภวิชญ์ ศรีภูสิตโต

14 กุมภาพันธ์ 2026

1 Introduction

วิศวกรเคมีควรมีองค์ความรู้เกี่ยวกับการแก้ Optimization problems ที่นอกเหนือจากแค่ Linear Programming แต่คณิตศาสตร์ที่สอนในภาคเรามันอ่อนแอมาก (โดยเฉพาะเมื่อเทียบกับภาคไฟฟ้า) การทำความเข้าใจ algorithm พื้นฐานจึงยังเป็นไปได้ยากแต่แรกเจอ 🤦 แต่ถ้าเราเจอมันมากกว่าแค่ครั้งเดียวเราเชื่อว่าทุกคนสามารถเข้าใจมันได้เหมือนที่เราเข้าใจในครั้งแรกได้ (แต่ไม่จำเป็นต้องเข้าใจแบบเราก็ได้มันทรมานเกินไปกว่าจะมาถึงจุดนี้ 🤦) ดังนั้นเราจะเริ่มปูพื้นฐานที่ทุกคนอาจพอเข้าใจอยู่แล้วอย่างเข้มงวดรัดกุมที่สุด (เท่าที่คิดว่าวิศวกรธรรมดาหนึ่งคนจะรับได้)

2 Gradient

สำหรับฟังก์ชันตัวแปรเดียวใน calculus เราเคยเจอ derivative ไปแล้ว แต่สำหรับ multivariable function เรามี partial derivative มากตามจำนวนตัวแปร มันคงจะดีถ้าเรามีบางสิ่งที่แสดงถึง partial derivative ทั้งหมดนั้นในตัวแปรเดียว สิ่งลึกลับที่เรียกว่า gradient จึงมีนิยามขึ้นดังสมการ

Gradient Definition

สำหรับฟังก์ชัน $f : \mathbb{R}^n \to \mathbb{R}$

จะมี gradient เป็นเวกเตอร์ใน space $\mathbb{R}^n$ คือ

$$grad(f) = \nabla f = \left\langle \frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \ldots, \frac{\partial f}{\partial x_n} \right\rangle = \begin{pmatrix} \frac{\partial f}{\partial x_1} & \frac{\partial f}{\partial x_2} & \cdots & \frac{\partial f}{\partial x_n} \end{pmatrix}^\top$$

ในบทความนี้กำหนดให้ gradient เป็น column vector (1 column n rows) ลำพังนิยาม gradient โดยไม่รู้สมบัติของมันก็ขยะอวกาศดี ๆ นี่เอง ดังนั้นต่อจากนี้เราจึงจะเรียนรู้ว่ามันพิเศษอย่างไร

2.1 Geometrical Interpretation of Gradient

จินตนาการคือกุญแจสำคัญของคณิตศาสตร์ขั้นสูงโดยเฉพาะสิ่งที่เป็นนามธรรมมาก ๆ หากเราจินตนาการเห็นภาพมันได้เราอาจเข้าใจมันอย่างทะลุปรุโปร่งได้ในเวลาสั้น ๆ โดยใช้แค่สมาธิเพ่งกับมันโดยไม่ต้องหาอะไรอ่านเพิ่มเติมได้ ดังนั้นเพื่อให้ทุกคนพอจะจินตนาการสิ่งที่เราเคยเห็นได้ การใช้เรขาคณิตที่เกี่ยวกับรูปทรงจึงเป็นทางที่ดีให้เริ่มฝึกจินตนาการ

เพื่อให้สะดวกในการจินตนาการง่ายที่สุดเราขอยกตัวอย่างเป็นเพียง 3 มิติ (เป็นมิติที่ไม่น้อยจนอธิบายลำบากและไม่มากจนจินตนาการไม่ถึง)
เริ่มจากฟังก์ชันพื้นผิวโค้ง

$$z = f(x, y)$$

เมื่อ x, y, z เป็นพิกัดในระบบพิกัดฉากที่เราคุ้นเคย
เราสามารถเขียนฟังก์ชันนี้เป็น 2 มิติได้โดยใช้ countour plot โดยเทคนิคในการวาดคือการหาเส้น isohypses โดยการแทนความสูง (z) เป็นค่าคงที่ใด ๆ นั่นคือการตั้งสมการ

$$f(x, y) = c$$

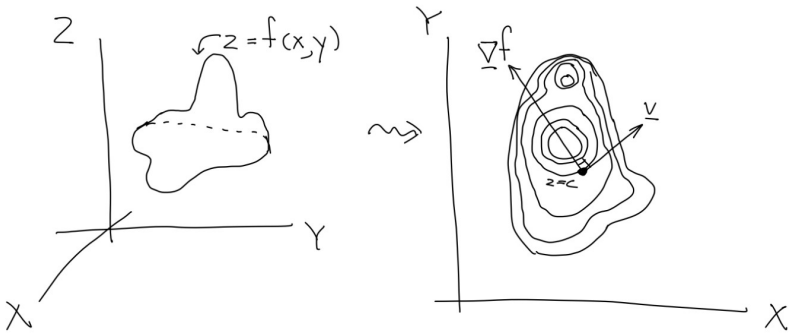
สมการดังกล่าวคือเส้นโค้ง 1 เส้น เส้นดังกล่าวอาจเรียกว่า level curve เพราะเป็นเส้นโค้งที่อยู่ในระดับความสูงเดียวกัน (และมี level surface กับ level set ที่ล้อเลียนมาในมิติที่สูงขึ้นอย่างพวกมิติกาลอวกาศ) แล้วถ้าเราหา derivative เทียบกับระยะเส้นโค้งล่ะ เราจะได้สมการ total derivative ดังนี้

$$\left.\frac{df}{dx}\right|_{z=c}\frac{dx}{ds}+\left.\frac{df}{dy}\right|_{z=c}\frac{dy}{ds}=0$$

ถึงจุดนี้หลายคนอาจไม่เข้าใจว่าเราทำไปทำไม แต่ถ้าจินตนาการออกจะเห็นอีกสมการหนึ่งซ่อนอยู่คือ

$$\left.\nabla f\right|_{z=c}\cdot\underline{v}=0$$

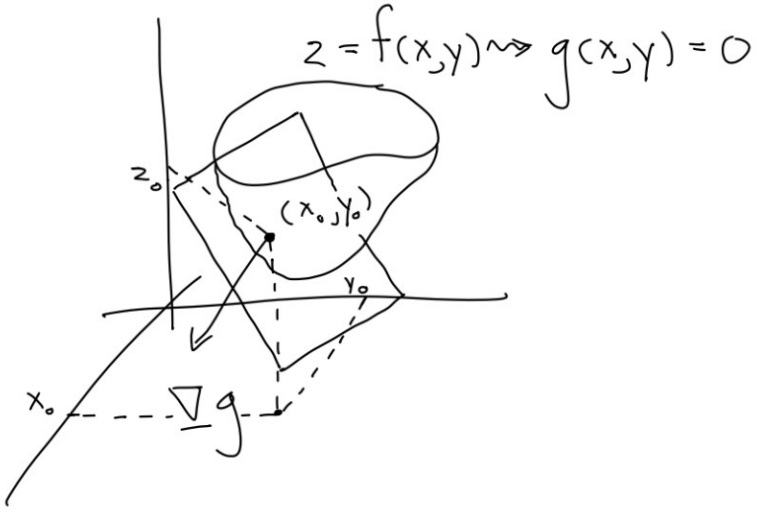
เมื่อจินตนาการซ้อนไปอีกจะเห็นว่าสมการดังกล่าวบอกเราว่าถ้า gradient และ $\underline{v}$ ต่างไม่ใช่เวกเตอร์ $\underline{0}$ ทั้งสองจะตั้งฉากกันซึ่งเป็นกรณีทั่วไป และ $\underline{v}$ คือเวกเตอร์ที่สัมผัสกับจุดใด ๆ บน level curve นี้ ดังนั้นเราจึงสรุปได้ว่า gradient จะตั้งฉากกับ level curve เสมอ (หากลองพิสูจน์อย่างรัดกุมมากขึ้นจะพบว่ามันตั้งฉากกับทุก level set) ตรงนี้ถ้าใครสงสัยว่าในเมื่อมันตั้งฉากมันก็ทำได้ 2 ทาง แล้วมันจะชี้ไปทางไหนเดี๋ยวรอดูต่อไปว่าเราจะพิสูจน์อย่างไร ถ้าวาดรูปที่เราอธิบายมาจะได้ดังนี้



แล้วการรู้ว่ามันตั้งฉากกับ level curve จะมีประโยชน์อะไรนอกจากจินตนาการให้ป่วยการล่ะ ถ้าจินตนาการการลาก gradient vector ตั้งฉากกับ level surface แทน เราจะได้ normal vector ของ tangent plane ของพื้นผิวนั้น ๆ นั่นหมายความว่าเราสามารถทำ linearization ด้วยเทคนิคที่ทรงพลังยิ่งขึ้น สำหรับใครที่ยังจินตนาการไม่ออกเริ่มจากการตั้งสมการของพื้นผิวนั้นขึ้นมาก่อนคือ $z=f(x,y)$ และถ้าเราเขียนใหม่เป็น $z-f(x,y)=0$ จะนิยามฟังก์ชันใหม่ในมิติที่สูงขึ้นคือ $g(x,y,z)=c=0$ เมื่อเรายกมิติของฟังก์ชันให้สูงขึ้นไปได้ และหา level surface ที่ตรงกับ actual surface ได้แล้วเราก็หา normal vector ที่จุดดังกล่าวของ surface ได้แล้ว และเรารู้ว่าจุดที่เราสนใจคือจุดไหน จึงเป็นการยืนยันการมีอยู่เพียงหนึ่งเดียวของ tangent plane นี้ เมื่อเราเขียนสมการดังกล่าวจะได้ว่า

$$\nabla g\cdot\langle x-x_0,y-y_0,z-z_0\rangle=0$$

รูปภาพการทำ linearization ที่ทุกคนอาจผ่านตามามากแล้วแสดงดังด้านล่าง



2.2 Directional Derivative & Steepest Descent

นอกเหนือจากที่กล่าวมาหลายคนอาจเคยสงสัยว่าทำไมเรามีแต่อัตราการเปลี่ยนแปลงตามแนวพิกัดฉากเท่านั้น แต่เมื่อเรารู้จัก gradient เรามามารถหามันได้แล้ว เพราะ derivative ดังกล่าวคือ projection ของ gradient ในทิศทางนั้น ๆ จึงเป็นนิยามของ Directional Derivative คือ

Directional Derivative Definition

Directional Derivative คือ derivative ในทิศทางนั้น ๆ นิยามโดย

$$D_{\hat{u}}f = \underline{\hat{u}} \cdot \nabla f$$

เมื่อ $\underline{\hat{u}}$ คือ unit vector ในทิศที่สนใจ

ตรงนี้เรารู้ว่า dot product ขึ้นกับ $\cos\theta$ ของมุมระหว่างทิศที่สนใจกับ gradient หมายความว่า directional derivative จะมีค่ามากสุดเมื่อ unit directional vector มีทิศเดียวกับ gradient นั่นคือ

gradient จะชี้ไปยังทิศที่ฟังก์ชันเพิ่มไวที่สุดเสมอ
และทิศที่ทำให้ฟังก์ชันเพิ่มไวที่สุด (Steepest Ascent) คือทิศของ gradient

3 Essence of Matrix Approach in Optimization

ส่วนนี้เป็นการตั้งสมการสำหรับ "การวิเคราะห์" ซึ่งเป็นตัวบ่งชี้ว่า Optimization ที่เราทำมามีความสำเร็จไหม ทำถูกทิศหรือเปล่า โดยเริ่มจากกำหนด $f = f(x_1, x_2, \ldots, x_n)$ เมื่อเขียนในรูป state vector จะได้ว่า $f = f(\underline{x})$ เมื่อ $x \in \mathbb{R}^n$ หากกำหนดจุด extrema คือ $(\underline{x}_c, f(\underline{x}_c))$ จะประมาณจุดที่ห่างจากจุดดังกล่าวเป็นระยะใด ๆ โดยใช้ Taylor's series ได้เป็น

$$f(\underline{x}_c + \underline{\Delta x}) = f(\underline{x}_c) + \nabla f\Big|_{x_c} \cdot \underline{\Delta x} + \frac{1}{2}\sum_{j=1}^{n}\sum_{i=1}^{n} \frac{\partial^2 f}{\partial x_i \partial x_j}\bigg|_{x_c} \Delta x_i \Delta x_j + \mathcal{O}(||\underline{x}||^2)$$

พิจารณาพจน์อันดับ 2 เป็น S จะได้ว่า

$$S = \frac{1}{2}\sum_{j=1}^{n}\left(\Delta x_j \sum_{i=1}^{n} \frac{\partial^2 f}{\partial x_i \partial x_j}\bigg|_{x_c} \Delta x_i\right)$$

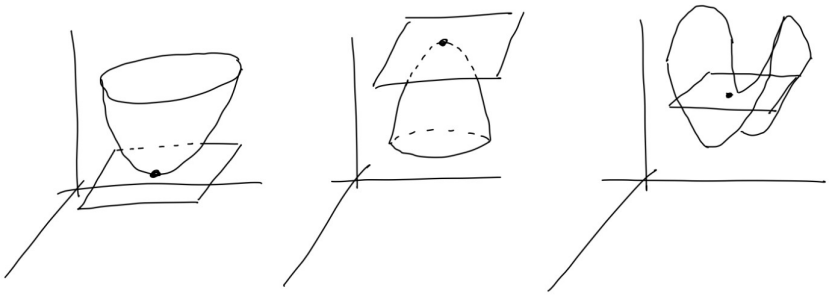
$$= \frac{1}{2}\sum_{j=1}^{n} \Delta x_j \begin{pmatrix} \partial^2 f/\partial x_1 \partial x_j \\ \partial^2 f/\partial x_2 \partial x_j \\ \vdots \\ \partial^2 f/\partial x_n \partial x_j \end{pmatrix} \cdot \underline{\Delta x}$$

$$= \frac{1}{2}\underline{\Delta x}^{\top} \begin{pmatrix} \frac{\partial^2 f}{\partial x_1 \partial x_1} & \frac{\partial^2 f}{\partial x_2 \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_1} \\ \frac{\partial^2 f}{\partial x_1 \partial x_2} & \frac{\partial^2 f}{\partial x_2 \partial x_2} & & \\ \vdots & & \ddots & \\ \frac{\partial^2 f}{\partial x_1 \partial x_n} & \frac{\partial^2 f}{\partial x_2 \partial x_n} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_n} \end{pmatrix} \underline{\Delta x}$$

Matrix ตรงกลางนั้นมีขนาดใหญ่มากจึงนิยามเป็น Hessian Matrix เพื่อความสะดวกในการเรียกใช้ ดังนั้นเราจะได้สมการใหม่คือ

$$f(\underline{x}_c + \underline{\Delta x}) - f(\underline{x}_c) \approx \nabla f\big|_{x_c}^{\top} \underline{\Delta x} + \frac{1}{2} \underline{\Delta x}^{\top} \underline{\underline{H}} \underline{\Delta x}$$

ข้อสังเกตสำหรับ Hessian matrix หนึ่งอย่างคือในกรณีทั่วไปในโลกจริงจะตรงตาม Clairaut's theorem ที่ partial derivative มีความสมมาตร นั่นคือสามารถสลับลำดับได้ ดังนั้น Hessian matrix จึงมีความสมมาตร กล่าวคือ $H = H^{\top}$ สำหรับการแก้ optimization problems อย่างแรกเราต้องหา critical point ก่อน ขั้นนี้เรารู้จากส่วนก่อนหน้าแล้วว่า gradient จะชี้ไปยัง steepest descent ดังนั้นหากเราอยู่ในจุด extrema แล้ว gradient จะเป็น zero vector แน่นอน หากเป็นกรณี 3 มิติจะเห็นว่า linearize plane จะขนานกับ xy-plane ดังรูป



แล้วเราจะตรัสรู้ได้ยังไงว่าจุดนั้นมันเป็น mimima maxima หรือ saddle point อย่างแรกเราต้องจินตนาการก่อนว่าสมการที่เราตั้งไว้ด้านบนมันคือการประมาณช่วงโค้งบริเวณ extrema ดังนั้นหากเราพิจารณาบริเวณใกล้ ๆ ว่าฟังก์ชันมัน convex concave หรือ inconclusive ได้ เราก็จะสรุปได้ว่า critical point ของเรามันคืออะไร อย่างแรกลองมองย้อนกลับไปหาภาพที่เราอธิบาย gradient กับ linearized plane สังเกตว่าไม่ว่าเราจะเลื่อนจุดไปทางไหนของ convex function จะเราได้ linearized plane อยู่ใต้ surface เสมอ นั่นหมายความว่า

$$\nabla f\big|_{(x,y)} \cdot \underline{\Delta x} \leq f(\underline{x} + \underline{\Delta x}) - f(\underline{x})$$

เมื่อนำมารวมกับสมการที่เราเพิ่งจะประมาณมาจะได้ว่า

$$\Delta x^{\top} H \Delta x \geq \underline{0}$$

กรณีทั่วไปเรามั่นใจว่า Δx ไม่มีทางเป็น 0 แน่นอน ดังนั้นจึงย้ายข้างสมการได้เป็น

$$H \geq \underline{\underline{0}}_{n \times n}$$

หลังจากนี้จะเป็นสิ่งที่เรียกว่า spectral analysis ซึ่งใช้จินตนาการมากพอสมควร (เหมือนชื่อมันนั่นแหละ spectral = เลือนลาง มองไม่เห็น) ดังนั้นเราจะเริ่มจากสิ่งที่ทุกคนมองเห็นก่อนคือ characteristic equation ของ eigenvalues & eigenvectors

$$Hv = \lambda v$$

เมื่อ H มีมิติเป็น $n \times n$ จะมี eigenvectors และ eigenvalues จำนวน n คู่ แล้วถ้าเราอยากรวบ n สมการมาเป็น matrix สมการเดียวล่ะ เราจะต้องมี matrix ที่เก็บ eigenvectors ทั้งหมดตามแถว นิยามเป็น

$$P = \begin{pmatrix} | & | & & | \\ v_1 & v_2 & \cdots & v_n \\ | & | & & | \end{pmatrix}$$

พิจารณาเฉาะฝั่งซ้ายของสมการจะได้เป็น

$$LHS = HP$$

ส่วนฝั่งขวาสมการนั้นเราต้องทำให้เข้ากับฝั่งซ้าย จะได้ว่า

$$RHS = P \begin{pmatrix} \lambda_1 & & & 0 \\ & \lambda_2 & & \\ & & \ddots & \\ 0 & & & \lambda_n \end{pmatrix}$$

เรานิยาม matrix ใหม่เป็น

$$\Lambda = \begin{pmatrix} \lambda_1 & & & 0 \\ & \lambda_2 & & \\ & & \ddots & \\ 0 & & & \lambda_n \end{pmatrix}$$

เมื่อนำทั้งสองข้างของสมการกลับมารวมกันจะได้ว่า

$$HP = \Lambda P$$

เมื่อย้ายข้างสมการ แล้วแทนค่า H กลับไปที่อสมการก่อนที่เราจะทำ spectral analysis จะได้ว่า

$$P\Lambda P^{-1} \geq \underline{\underline{0}}_{n \times n}$$

แน่นอนว่า eigenvector ในกรณีทั่วไปก็มักไม่เป็น $\underline{0}$ อยู่แล้ว เมื่อย้ายข้างอสมการอีกครั้งจะได้ว่า

$$\Lambda \geq \underline{\underline{0}}_{n \times n}$$

นั่นหมายความว่าทุก eigenvalue ของ Hessian matrix มากกว่า 0 เมื่อบริเวณดังกล่าวเป็น convex function และด้วยแนวคิดเดียวกันสำหรับ concave function จะเปลี่ยนมากเป็นน้อยกว่าแทน ส่วน saddle point จะสังเกตว่า linearized plane จะมีบางส่วนอยู่เหนือ บางส่วนอยู่ใต้ surface นั่นคือ eigenvalue บางตัวจะมากกว่า 0 และบางตัวน้อยกว่า 0 ส่วนกรณีที่เป็น 0 ทั้งหมดนั้นจะสรุปไม่ได้ หากเขียนทั้งหมดเป็นเกณฑ์สั้น ๆ จะได้ว่า

all $\lambda_i \geq 0$, convex function
all $\lambda_i \leq 0$, concave function
some λ_i is positive and some negative, saddle point
all $\lambda_i = 0$, inconclusive

4 Gradient Descent

ระเบียบวิธี Gradient Descent มีต้นคิดมาจากการมองว่าถ้าเราเดินตรงข้ามกับ gradient เราจะเข้าสู้ค่าต่ำสุดของฟังก์ชันได้เร็วที่สุด ดังนั้นทิศทางการเดินในแต่ละขั้นคือ gradient ที่จุดนั้น ๆ ส่วนความยาวในการเดินนั้นเป็นความยาวที่เดาว่าจะไม่ทำให้ diverges จาก optimum value จึงใช้วิธี line search ดังนั้นสำหรับวิธีหาทิศทางทุกคนจึงรู้จากส่วนก่อนหน้าแล้ว (เราจึงไม่ต้องซ้ำ) ในที่นี้เราจึงจะอธิบายแค่ numerical line search เท่านั้น ขั้นตอนของวิธีนี้เป็นไปอย่างมีระบบดังนี้

1. หา parametric equation ของเส้นทางที่เราจะเดิน คือ $\underline{x}_{n+1} = \underline{x}_n + s\nabla f$ เมื่อ s เป็น parametric variable และเป็นระยะที่ต้องเดินที่เราจะหาด้วย

2. สุ่มตัวเลขสักตัวมาใส่ s ถ้าค่านั้นทำให้ฟังก์ชันมากขึ้นให้ลดลงมาหาตัวที่ทำให้ค่าของฟังก์ชันน้อยลง ถ้าค่านั้นทำให้ฟังก์ชันลดลงให้เพิ่มหาค่าที่ทำให้ฟังก์ชันมากขึ้น ในที่นี้เราจะได้ s ทั้งหมด 2 ค่า รวมที่ s = 0 ด้วยจะเป็น 3 ค่า

3. นำค่า s ทั้ง 3 มา interpolate แล้วหาจุดต่ำสุด จุดดังกล่าวคือระยะที่เราต้องใช้เดิน

การวิเคราะห์เพิ่มเติมพิจารณาที่ขั้นตอนที่ 3 พบว่าสามารถสร้างสูตรสำเร็จได้โดยการ interpolate โดยใช้ Lagrange's polynomial จะได้ว่า

$$f = \frac{(s-s_2)(s-s_3)}{(s_1-s_2)(s_1-s_3)}f(s_1) + \frac{(s-s_1)(s-s_3)}{(s_2-s_1)(s_2-s_3)}f(s_2) + \frac{(s-s_1)(s-s_2)}{(s_3-s_1)(s_3-s_2)}f(s_3)$$

เมื่อหาจุดต่ำสุดจะได้สมการ

$$0 = \frac{2s-s_2-s_3}{(s_1-s_2)(s_1-s_3)} + \frac{2s-s_1-s_3}{(s_2-s_1)(s_2-s_3)} + \frac{2s-s_1-s_2}{(s_3-s_1)(s_3-s_2)}$$

เมื่อแทนค่าลงไปจะได้สมการเชิงเส้นตัวแปรเดียวธรรมดาที่หาค่า s ได้ง่าย หลังจากนั้นจึงนำไปทำตามขั้นตอนต่อไปเลย